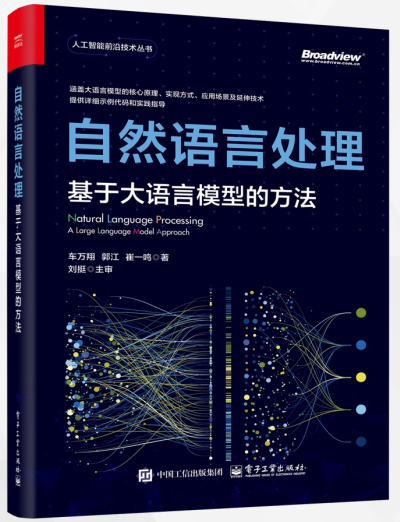


自然语言处理基础

车万翔

社会计算与交互机器人研究中心（HIT-SCIR）
哈尔滨工业大学

本讲内容与学习目标

内容	学完后能够
文本表示	解释词和句子怎样变成向量
自然语言处理任务	根据输入和输出识别任务
基本问题	区分分类、结构预测与序列生成
评价指标	手算指标，并说明指标的局限

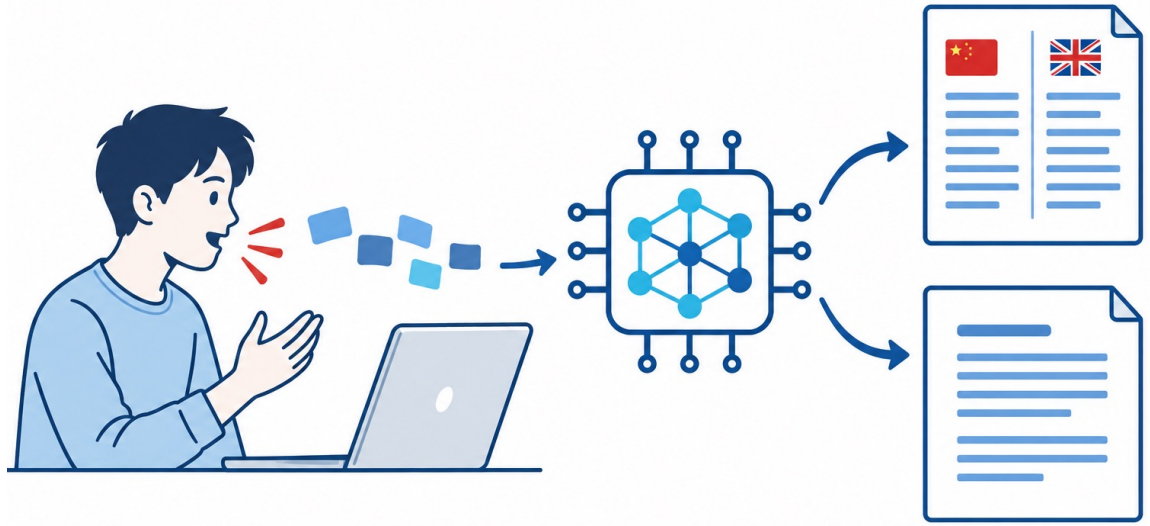
文本表示：计算机怎样处理一句话

“我喜欢自然语言处理”

字符串　　记录文字与顺序

处理单元　　字、词或词元（Token）

数字向量　　模型用来计算的表示



词的独热表示

词表中的每个词占据一个位置

词	我	喜欢	自然	语言
我	1	0	0	0
喜欢	0	1	0	0
自然	0	0	1	0
语言	0	0	0	1

维度 等于词表大小

稀疏 只有一维为1

局限 不同词之间缺少语义相似性

“喜欢”和“爱”即使含义接近，也对应不同的独热坐标。

词的分布表示：共现矩阵

我 喜欢 自然 语言 处理 。
我 爱 深度 学习 。
我 喜欢 机器 学习 。

上下文相似的词，
往往具有相近的含义。

词 / 上下文	我	喜欢	自然	语言	处理	爱	深度	学习	机器	。
我	0	2	1	1	1	1	1	2	1	3
喜欢	2	0	1	1	1	0	0	1	1	2
自然	1	1	0	1	1	0	0	0	0	1
语言	1	1	1	0	1	0	0	0	0	1
处理	1	1	1	1	0	0	0	0	0	1
爱	1	0	0	0	0	0	1	1	0	1
深度	1	0	0	0	0	1	0	1	0	1
学习	2	1	0	0	0	1	1	0	1	2
机器	1	1	0	0	0	0	0	1	0	1
。	3	2	1	1	1	1	1	2	1	0

每行是一个词的向量。上下文也可以选固定窗口或整篇文档。

PMI与PPMI：共现是否超出预期

$$PMI(w,c) = \log_2 [\, P(w,c) / (P(w)P(c)) \,]$$

实际共现与独立预期比较	PMI
高于预期	大于0
等于预期	等于0
低于预期	小于0

例子：“爱”和“深度”

实际共现：1
独立预期：$4 \times 4 / 70$
$PMI = \log_2(70/16) \approx 2.13$

$$PPMI(w,c) = \max(PMI(w,c), 0)$$

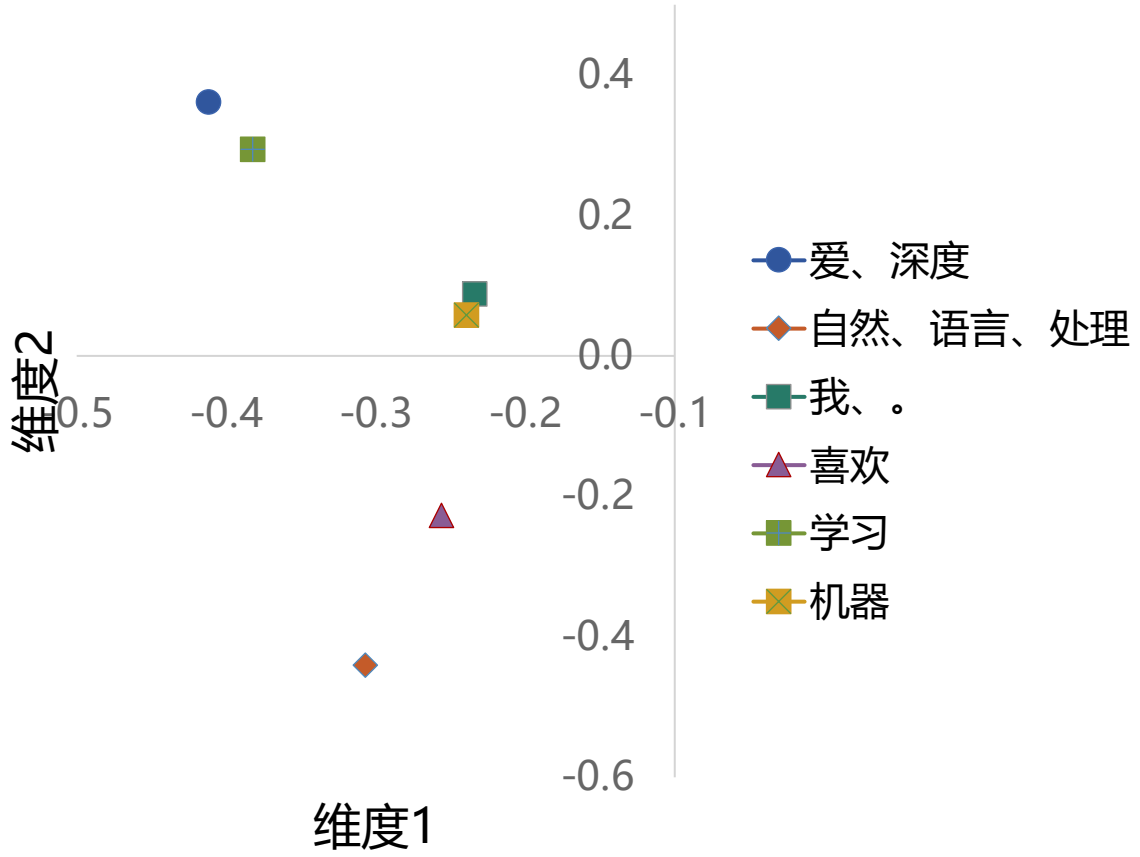
SVD：把高维表示压缩到低维

$$M = U\Sigma V^T$$

保留最大的d个奇异值
每个词用d维向量表示

这里：10维压缩到2维

利用整体共现模式
进行低秩近似



词向量化

词向量表示（Word Vector）

- 用连续、低维且稠密的向量来表示词汇，也被称作**词嵌入表示**（Word Embedding）

借助 torch.nn 包所提供的词向量层，能够将词元（通常是词的 ID）转换向量

```
>>> embedding = nn.Embedding (8, 4) # 词表大小为8，Embedding向量维度为4
>>> input = torch.tensor ([[0 , 1, 2, 3], [4, 6, 7, 7]] , dtype= torch.long)
# 输入形状为(2,4)的整数张量（相当于两个长度为4的整数序列），其中每个整数范围在0～7
>>> output = embedding (input) # 调用Embedding对象
>> print (output) # 输出结果，其中将相同的整数映射为相同的向量
tensor([[[ 0.7372,  0.8602,  0.8686, -1.3317],
         [-1.7751, -0.0850, -0.5261, -1.4419],
         [ 0.0032,  0.7363, -0.4184, -0.6436],
         [-0.2560, -0.2876,  0.0375, -0.9433]],

        [[ 0.1856, -1.9442,  0.4910, -1.0904],
         [ 0.4182,  0.2719, -0.4366,  1.6924],
         [-0.0087,  0.1504, -0.9328,  1.9001],
         [-0.0087,  0.1504, -0.9328,  1.9001]]], grad_fn=<EmbeddingBackward0>)
>>> print (output.shape)
# 输出张量形状为(2, 4, 4)，即在原始输入最后增加一个长度为4的维
torch .Size ([2 , 4, 4])
```

词嵌入与上下文表示

词嵌入 低维、稠密的连续向量
向量值随训练目标调整

静态表示 同一个词通常使用
同一个词向量

上下文表示 结合当前句子计算
同一个词可以得到不同表示



“苹果很甜”
“苹果发布了新品”

句子的词袋表示：把词向量相加

句子不同，词袋向量可能完全相同

句子	张三	打	李四
张三 打 李四	1	1	1
李四 打 张三	1	1	1

优点　　简单，容易与分类模型结合

局限　　丢失词序，难以表达角色与否定范围

中文文本通常没有显式的词间空格

研究生命的起源

切分	读出的含义
研究 / 生命 / 的 / 起源	研究“生命的起源”
研究生 / 命 / 的 / 起源	词典匹配可能产生的错误结果

分词需要结合上下文，边界也与标注规范有关。

最大匹配分词

词典：研究生、研究、生命、的、起源
最长词3字，匹配失败时按单字切分

方法	尝试次序	本例结果
正向最大匹配	从左向右，先尝试最长词	研究生 / 命 / 的 / 起源
逆向最大匹配	从右向左，先尝试最长词	研究 / 生命 / 的 / 起源

为什么局部的“最长词”不一定给出整句的最佳切分?

词元化（Tokenization）

以词作为基本处理单元的问题

- 词语存在复杂的词形变化，导致数据稀疏
- 词表规模过大，增加参数量，降低处理速度
- 针对不同语言单独进行分词处理

将单词分割成多个连续的词元（Token），该操作被称作词元化（Tokenization）

- 如：tokenization → tokeniza tion

子词切分：词表大小与序列长度

Token可以是字、子词或完整词

粒度	示例：computers	常见取舍
字符	c o m p u t e r s	词表较小，序列较长
子词	computer s（教学示意）	共享片段，平衡两端
整词	computers	序列较短，词表可能很大

同类词形：computer、computers、computing

子词不一定对应语言学上的词根或词缀，实际结果由分词器决定。

BPE训练：反复合并高频相邻单元

词及频次	初始切分	第一轮	第二轮
lower × 2	l o w e r </w>	l o w e r </w>	l o w e r </w>
newest × 6	n e w e s t </w>	n e w es t </w>	n e w est </w>
widest × 3	w i d e s t </w>	w i d es t </w>	w i d est </w>

第一轮 e + s 合并为 es，共现6 + 3 = 9次

第二轮 es + t 合并为 est，共现9次

并列频次按约定处理，本例先选e+s。</w>是词尾标记。

BPE编码：按合并优先级处理新文本

学到的顺序	合并规则
1	b + c 合并为 bc
2	a + b 合并为 ab

新输入：a b c

先使用规则1：a / bc
规则2此时无法应用

处理方式	结果
按BPE合并优先级	a / bc

词性标注：词在句中起什么作用

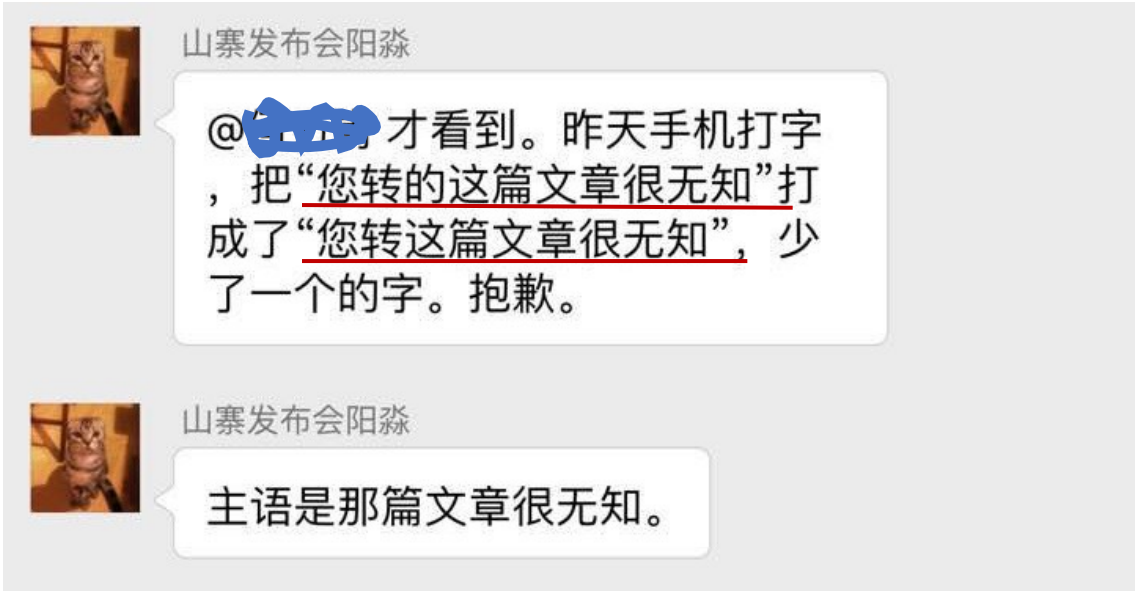
他 喜欢 下 象棋 。

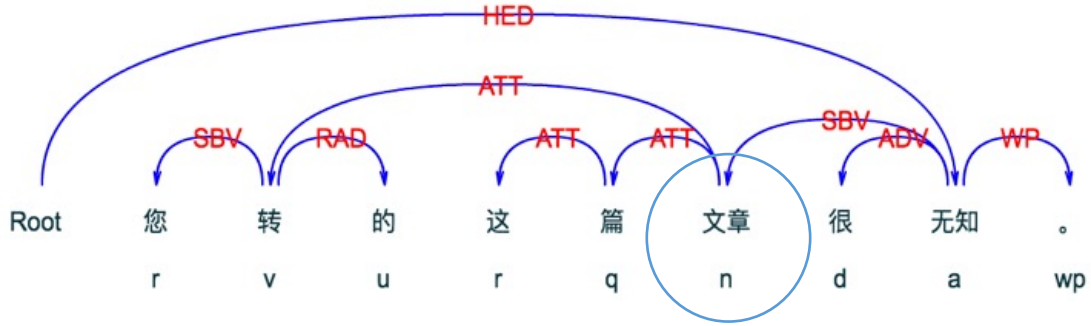
词	他	喜欢	下	象棋	。
词性标签	PN	VV	VV	NN	PU
含义	代词	动词	动词	名词	标点

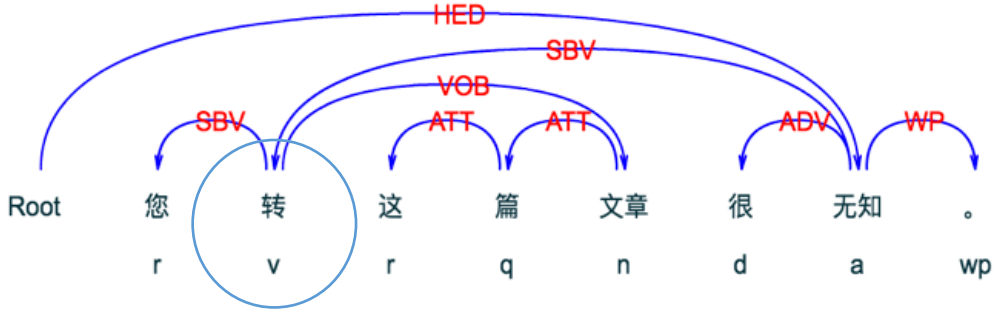
“下象棋”和“桌子下”中的“下”，作用相同吗?

句法分析：一个“的”改变句子结构

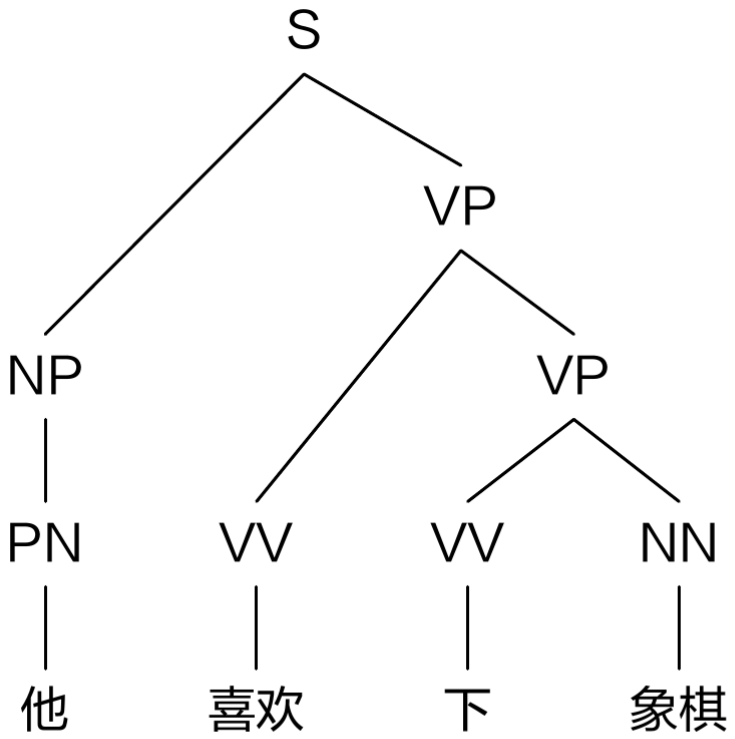
- 分析句子的句法成分，如主谓宾定状补等
- 将词序列表示的句子转换成树状结构







短语结构：词组成短语和句子



(a) 短语结构句法树

依存结构：词与词的支配关系



(b) 依存结构句法树

词义消歧与语义角色标注

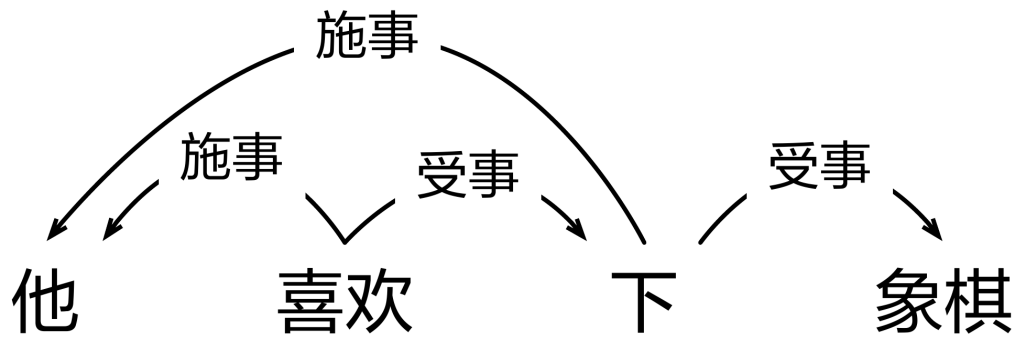
词义消歧　　“银行存款”中的“银行”表示什么?

语义角色　　谁在何时、何地做了什么?

张三 今天 在教室 讲课

谓词	施事	时间	地点
讲课	张三	今天	在教室

语义依存：直接表达语义关系



“他”同时参与两个谓词，
同一个词可以有多个入边。

语义解析：把问题转成可执行查询

查询年龄大于18岁的学生姓名

name	age
张三	18
李四	19

```
SELECT name FROM students
WHERE age > 18;
```

查询结果：李四

历史案例

“10月28日，AMD宣布斥资350亿美元收购FPGA芯片巨头赛灵思。”

抽取对象	结果
公司实体	AMD、赛灵思
事件及参与者	宣布收购，收购方AMD，对象赛灵思
金额与时间	350亿美元，10月28日

情感分析：整体态度与评价对象

“这款手机屏幕不错，但续航很差。”

任务粒度	输出示例
整句情感分类	存在正负混合态度
方面级观点抽取	屏幕：正面；续航：负面
观点三元组	(屏幕，不错，正面) (续航，很差，负面)

“真耐用，用一小时就没电了。”可能是什么情感?

问答系统：答案来自哪里

类型	主要信息来源	处理方式
检索式问答	网页或文档	检索相关内容并组织答案
知识库问答	结构化实体与关系	把问题映射为结构化查询
FAQ问答	已有问答对	匹配相似问题，返回已有回答
阅读理解	给定篇章	从篇章中抽取或生成答案

机器翻译与对话任务

机器翻译　　I love you. 对应“我爱你。”
输入和输出可以具有不同长度

对话系统　　根据当前输入和对话历史产生回复

对话目标	课堂例子
完成任务	查询车次、预约实验室
学习知识	解释什么是词嵌入
开放聊天	讨论兴趣爱好等

任务型对话：为什么还要追问

“帮我订一张明天去北京的机票。”

处理环节	当前信息或动作
理解输入（NLU）	意图：订票；目的地：北京；日期：明天
维护对话状态	数量：1；出发地：尚未提供
选择下一步策略	追问缺失的出发地
生成回复（NLG）	“请问您从哪里出发？”

三类基本问题

问题形式	输出长什么样	例子
文本分类	一个或多个类别	情感分类、句对关系判断
结构预测	标签序列、片段或图	词性、实体识别、句法树
序列到序列	长度可变的输出序列	翻译、摘要、回复

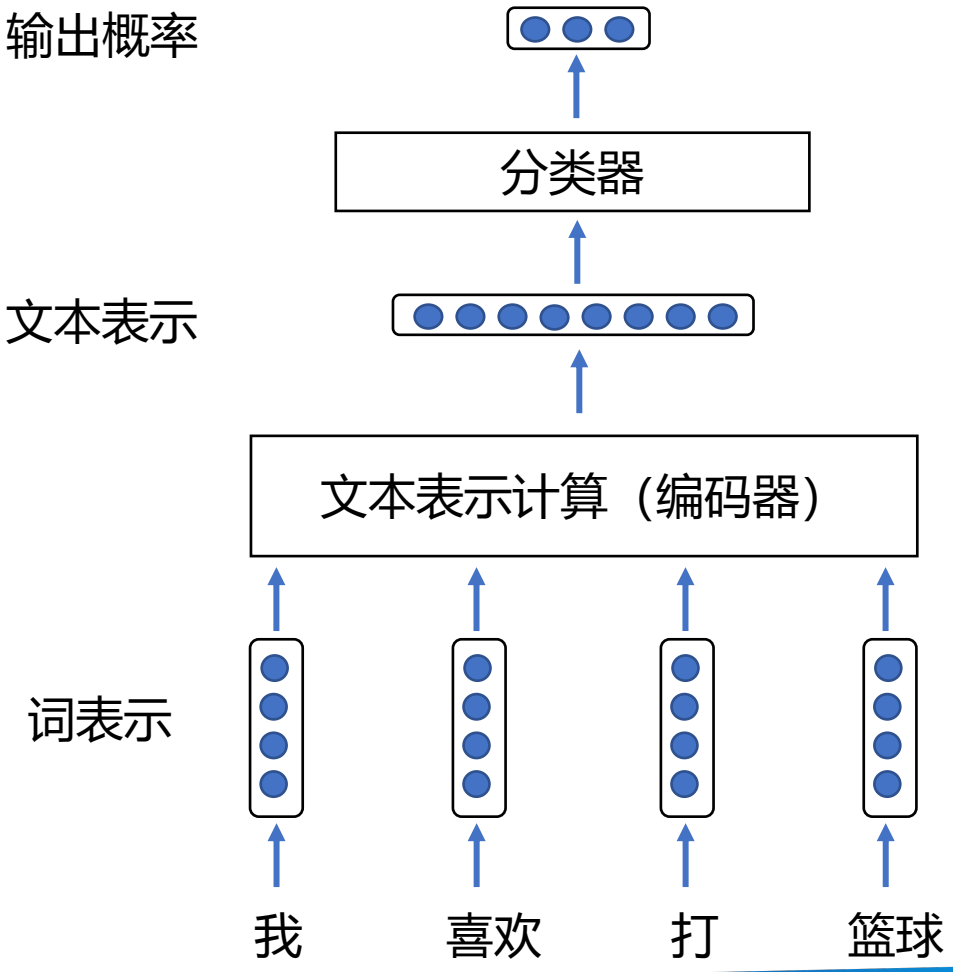
任务说明“要做什么”，问题形式说明“怎样表达输出”。

输入文本，输出预定义类别

输入 “我喜欢打篮球”

类别 体育 / 财经 / 教育

学习目标 利用标注样例
预测正确类别



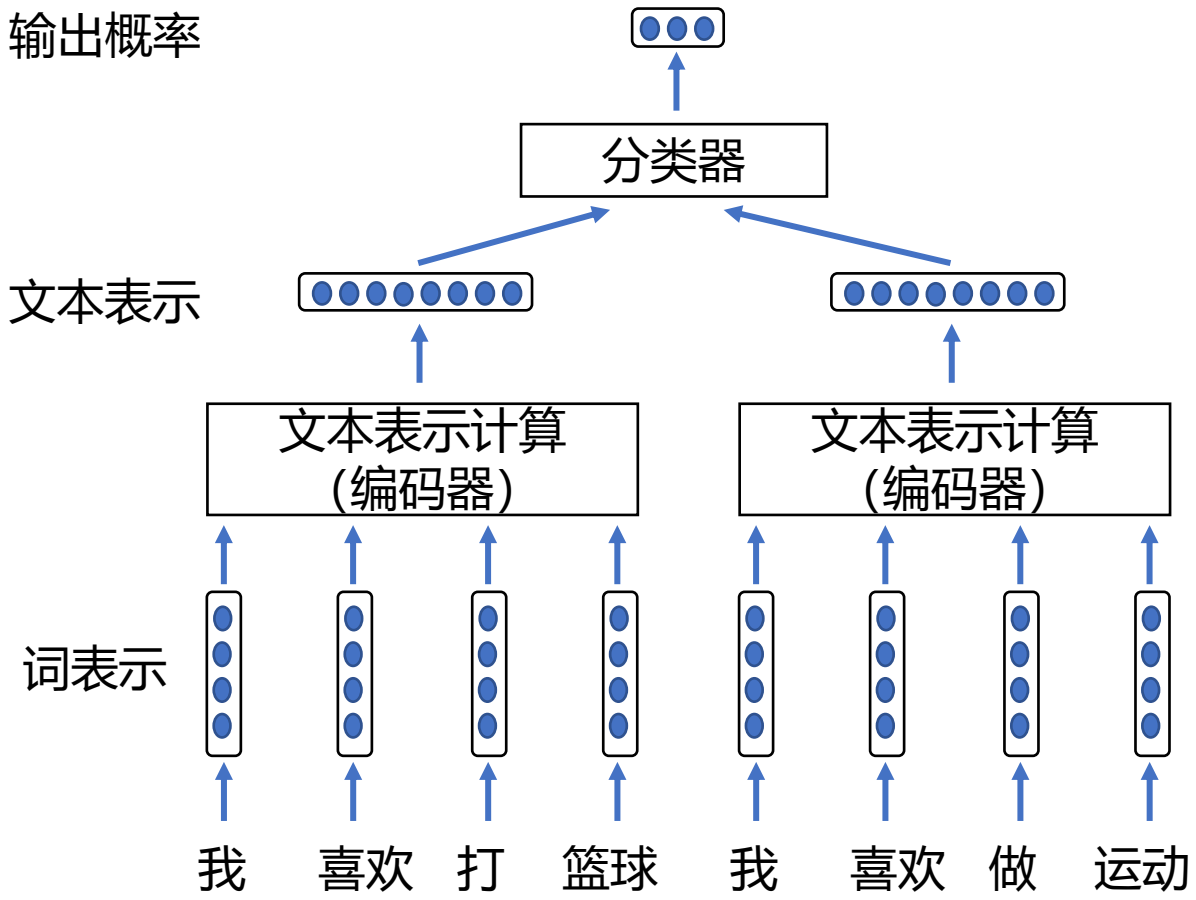
文本匹配：判断句对关系

输入：两段文本
输出：关系类别或相似度

双塔　分别编码两段文本
便于预计算与检索

单塔　联合编码两段文本
直接建模词间交互

“喜欢打篮球”通常蕴含“喜欢做运动”，反向呢?



双塔结构示意图

分词结果：我 / 爱 / 北京 / 天安门 / 。

输入	我	爱	北	京	天	安	门	。
BI	B	B	B	I	B	I	I	B
BMES	S	S	B	E	B	M	E	S

BI B表示词首，I表示词内

BMES B开始，M中间，E结束，S单字词

命名实体识别与BIO标签

实体：张三（人名）、哈尔滨（地点）

字	张	三	是	哈	尔	滨	人	。
BIO	B-PER	I-PER	O	B-LOC	I-LOC	I-LOC	O	O

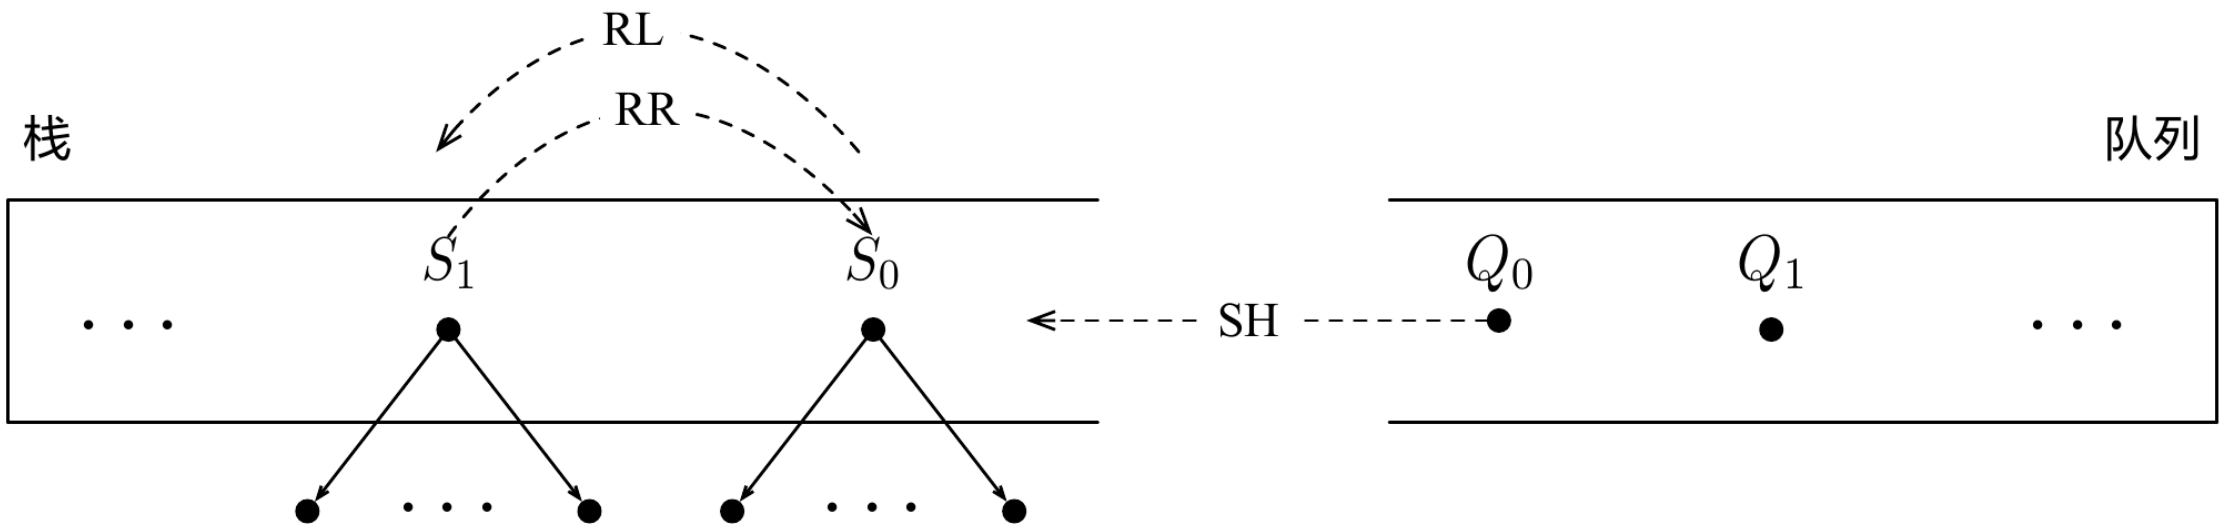
边界　　B为实体开始，I为实体内部，O为实体外

类别　　PER表示人名，LOC表示地点

图结构生成：边打分与动作序列

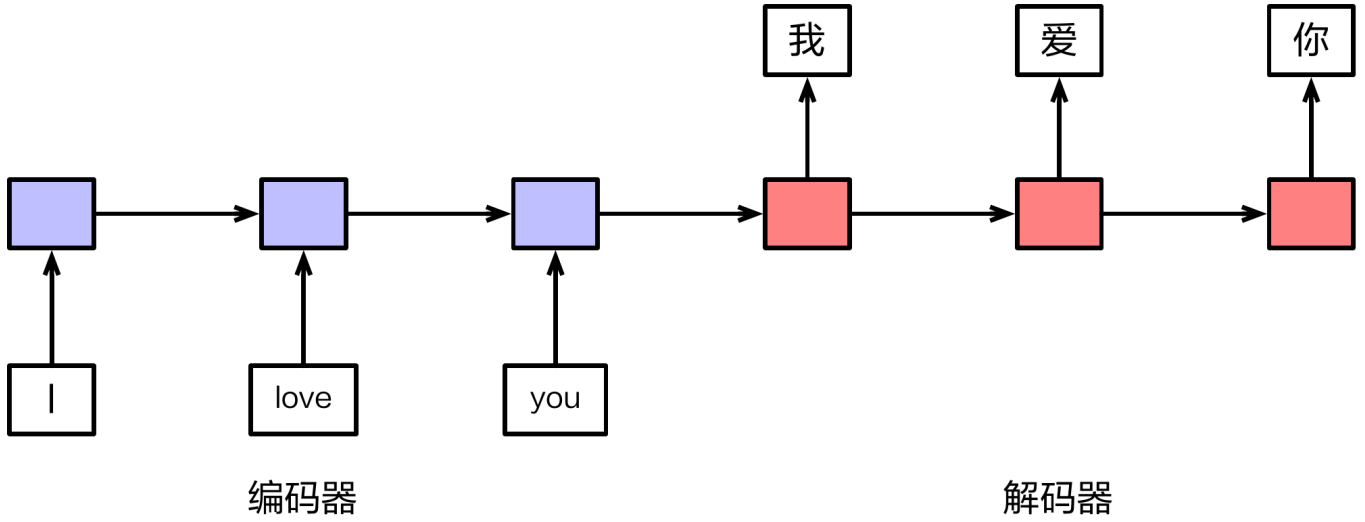
基于图　　为候选边打分，再解码出符合约束的结构

基于转移　　根据当前状态逐步选择动作，构建结构



序列到序列：按步生成输出

任务	输入	输出
翻译	源语言文本	目标语言文本
摘要	原文	较短的摘要
回复	对话历史与当前问题	回复文本



准确率：预测正确的比例

Accuracy = 正确预测数 / 总样本数

教学数据：100封邮件	数量	全部预测“正常”的结果
正常邮件	95	95封正确
垃圾邮件	5	5封全部漏掉

准确率 = 95%
垃圾邮件召回率 = 0%

实体级Precision、Recall与F1

原文	张	三	是	哈	尔	滨	人	。
标准	B-PER	I-PER	O	B-LOC	I-LOC	I-LOC	O	O
预测	B-PER	O	O	B-LOC	I-LOC	I-LOC	O	O

Precision 正确实体数 / 预测实体数 = 1 / 2

Recall 正确实体数 / 标准实体数 = 1 / 2

F1 2PR / (P + R) = 0.50

字级准确率7/8 = 87.5%，严格实体F1只有50%

依存分析的UAS与LAS

词	标准中心词	预测中心词	标准关系	预测关系
他	喜欢	喜欢	sub	sub
喜欢	ROOT	ROOT	root	root
下	喜欢	喜欢	obj	sub
象棋	下	喜欢	obj	obj

UAS：中心词正确，3/4 = 75%

LAS：中心词与关系都正确，2/4 = 50%

生成评价：BLEU与ROUGE

指标	比较什么	使用时需说明
BLEU	n-gram重叠精确率 结合长度惩罚	分词、n阶数、平滑等
ROUGE	n-gram或最长公共子序列 与参考文本的重叠	ROUGE-N或ROUGE-L 以及Precision/Recall/F1

参考：实验改到周五。
候选：实验改到周四。

字面重叠很高，关键日期仍然可能错误。

评价结果的可比性

数据集合	用途
训练集	学习模型参数
验证集	选择模型、超参数或提示方案
测试集	方案确定后报告最终效果

防止泄漏　　同一文本或近重复文本不应跨集合出现

课堂练习：课程通知助手

通知：“9月18日14:00在实验楼302上课。
全班40人分成4组，当天8人请假。”

任务识别　提取时间与地点，属于哪类任务和基本问题？

问答依据　问“在哪里上课”，系统应引用什么？

计算指标　标准4个实体，预测3个，2个完全正确。P、R、F1是多少？

信息边界　能否据此回答“每组当天有几人到课”？

本讲小结

主线	本讲要记住的内容
表示	独热、共现、PPMI、SVD、词嵌入、词袋
任务	分词、词性、句法、语义与应用任务
问题形式	文本分类、结构预测、序列到序列
评价	准确率、严格实体F1、UAS/LAS、BLEU/ROUGE

课后：实现最大匹配，复现PPMI与SVD，再比较模型分词结果。

选读：常见子词算法与工具

名称	核心思路
BPE	训练反复合并高频相邻单元，编码依合并优先级
WordPiece	常见编码按词内最长前缀匹配
Unigram	用概率模型比较候选切分
SentencePiece	支持BPE、Unigram等方法的分词工具

谢 谢!

理解语言，认知社会

以中文技术，助民族复兴



长按二维码，关注哈工大SCIR

微信号：HIT_SCIR