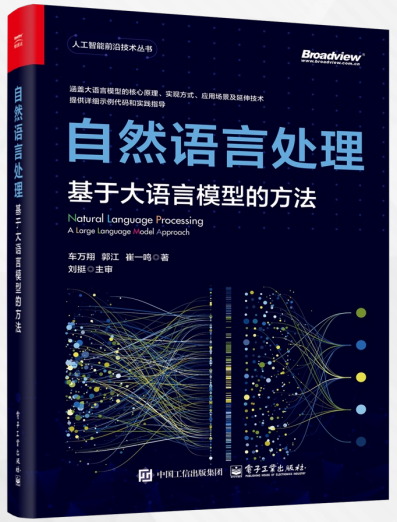


大语言模型的适配

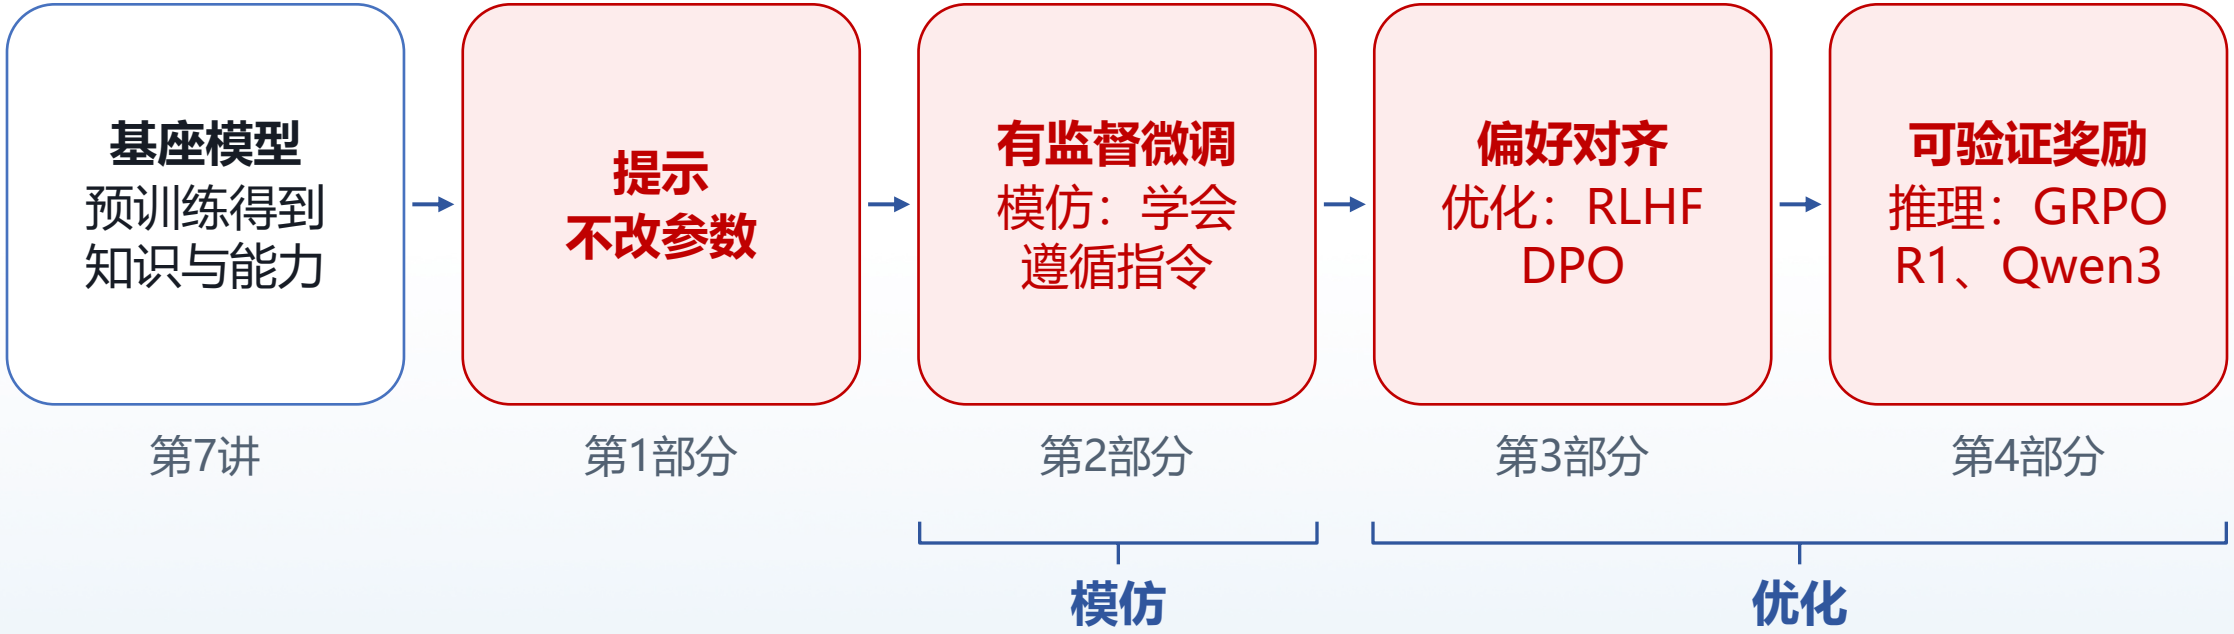
车万翔

社会计算与交互机器人研究中心（HIT-SCIR）
哈尔滨工业大学

本讲内容与学习目标

课堂内容	学习目标
基于提示的推断	会设计提示，理解思维链、自洽采样与检索增强
有监督微调	理解指令数据的构成，以及数据怎样影响模型
偏好对齐：RLHF与DPO	掌握奖励模型、PPO与DPO，了解它们的副作用
可验证奖励与推理模型	理解GRPO，以及R1、Kimi k1.5、Qwen3的训练流程
导入、方法选择与小结	能为具体需求选择适配方法

什么是“适配”：后训练全景



模仿与优化　　SFT拟合示范回答；RLHF与RLVR最大化奖励

提示的要素与通用技巧

指令	上下文	输入数据	输出指示
对任务的描述	外部信息或背景	用户的内容或问题	输出的类型或格式

好的提示	差的提示	好在哪里
提取文中所有公司名称及其所属国家，列成两列表格：公司名称、国家	提取文章中的公司	明确了要提取的信息和输出格式
分析XYZ公司2023年前三季度的销售数据，重点关注各地区的增长趋势，总结为结构化报告	销售数据说明了什么	指明了时间范围、对象和关注点
判断以下评论的情感是积极、消极还是中立，并用一句话说明理由	这个评论好还是不好	明确了标签集合和需要的解释

技巧：具体、给背景、指定格式；说“要做什么”，不说“不要做什么”。

上下文学习：在提示中给出示例

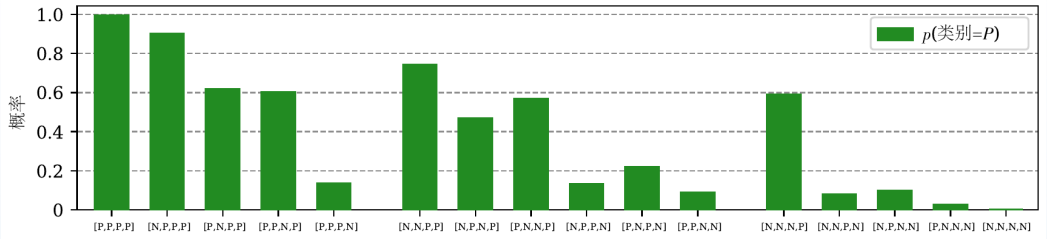
```
A "whatpu" is a small, furry animal native to
Tanzania. An example of a sentence that uses
the word whatpu is:
We were traveling in Africa and we saw these
very cute whatpus.

To do a "farduddle" means to jump up and down
really fast. An example of a sentence that uses
the word farduddle is:
One day when I was playing tag with my little
sister, she got really excited and she started
doing these crazy farduddles.

A "yalubalu" is a type of vegetable that looks
like a big pumpkin. An example of a sentence
that uses the word yalubalu is:
```

不更新参数　模型只读提示，参数完全不变

示例的作用　说明任务格式与输出空间



横轴：4个示例的标签组合（P正面、N负面）
纵轴：模型预测为“正面”的概率
示例一变，预测就大幅波动

Brown等，GPT-3，NeurIPS 2020；右图：Zhao等，Calibrate Before Use，ICML 2021。

示例带来的偏置与上下文校准

多数标签偏置
倾向于示例中出现最多的标签

近期偏置
倾向于最后一个示例的标签

高频词偏置
倾向于预训练中常见的词

$$q(y|x) \propto p(y|x) / p(y|N/A)$$

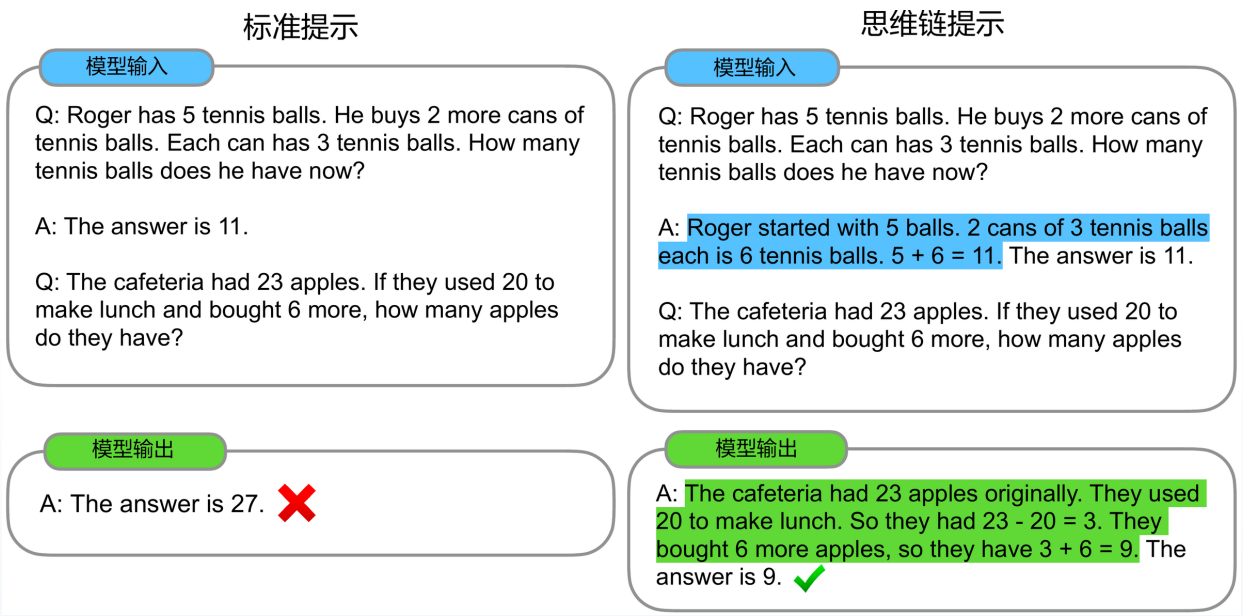
先输入无内容的“N/A”，估计先验偏向
除以该偏向再归一化，
使N/A的预测变成均匀分布

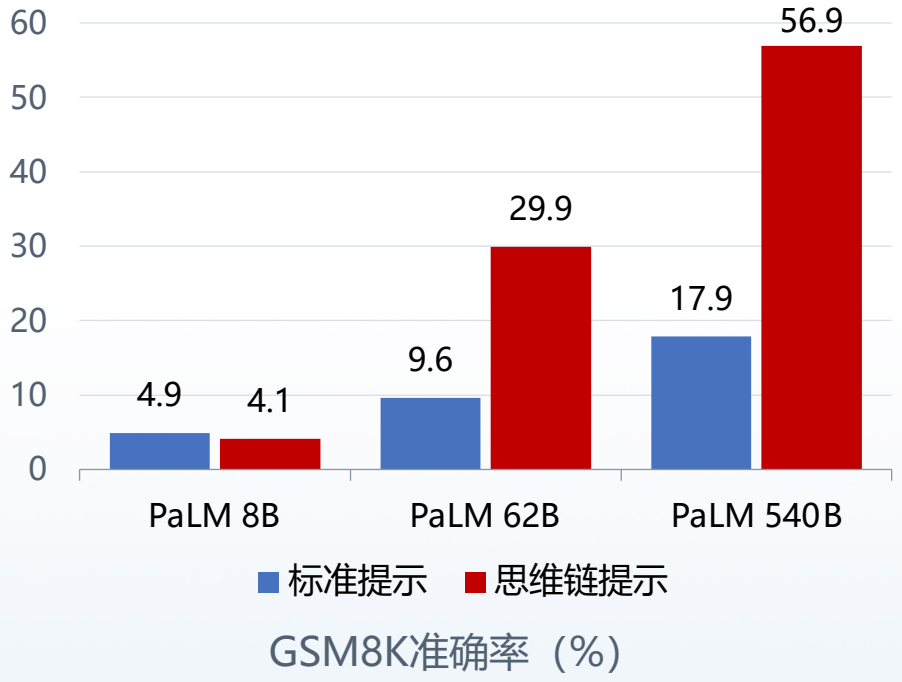
	正面	负面
N/A的预测	0.70	0.30
测试样本（原始）	**0.60**	0.40
校准后	0.39	**0.61**

原判为正面，校准后改判为负面

指令微调后的模型偏置减轻，但对示例仍然敏感。示例的选择与排列技巧见讲授备注。

思维链提示

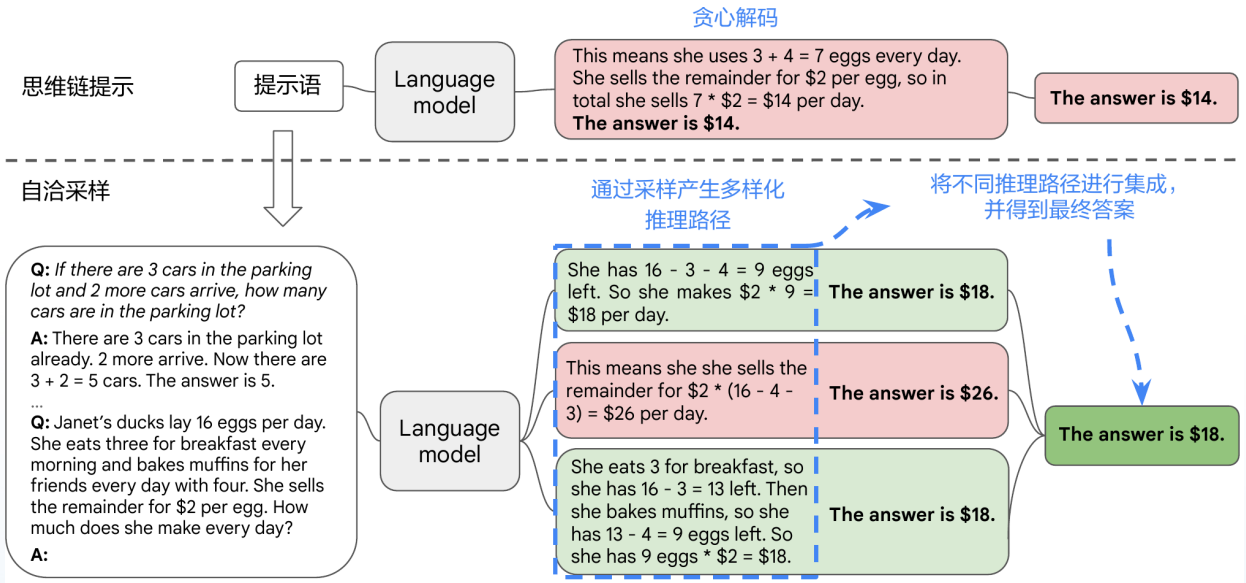


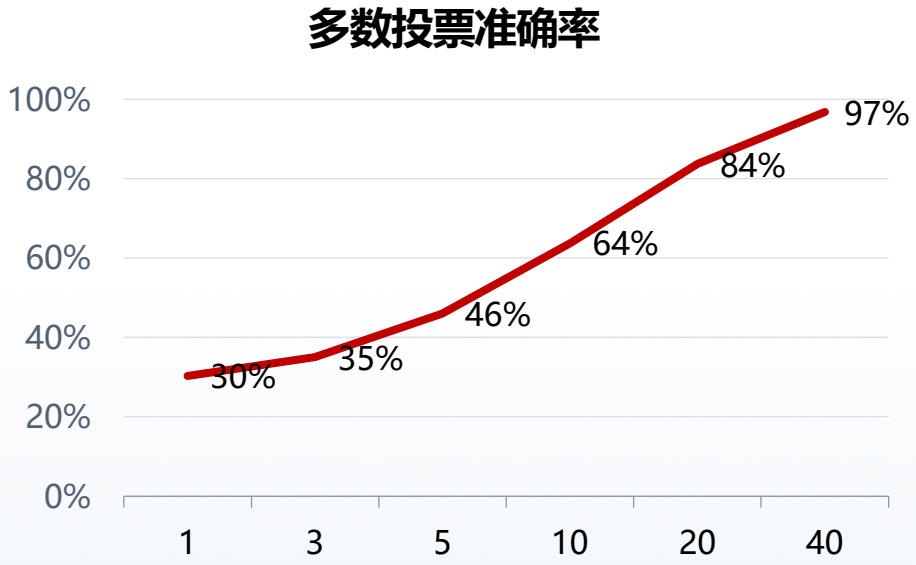


零样本思维链　只加一句“Let's think step by step”：GSM8K 10.4% → 40.7%

Wei等，NeurIPS 2022。零样本：Kojima等，NeurIPS 2022。

自洽采样与思维树





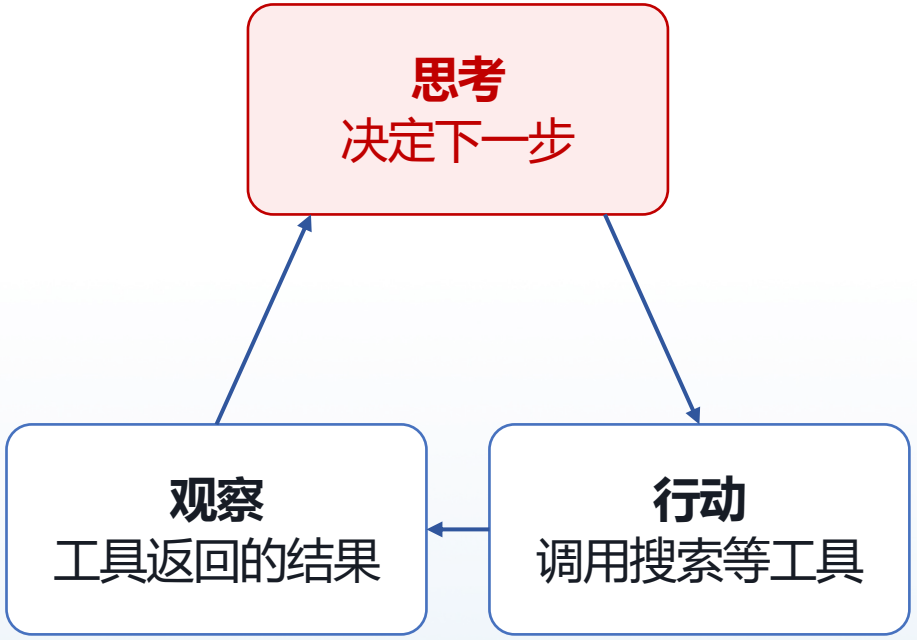
模拟：单条推理链准确率30%，
错误答案分散在10个值上（横轴：推理链数）

自洽采样 PaLM 540B，GSM8K：贪心思维链56.5% → 投票74.4%（40条推理链）

思维树 每一步展开多个想法并搜索：24点游戏中思维链4% → 思维树74%

Wang等，ICLR 2023；Yao等，NeurIPS 2023

ReAct：推理与行动交替



循环直到模型输出“Finish[答案]”
外部知识来自工具，而不是模型的记忆

问题：提出Transformer的论文发表在哪年的哪个会议？
思考1：先找到提出Transformer的论文。
行动1：Search[Transformer 原始论文]
观察1：Attention Is All You Need，Vaswani等。
思考2：再查这篇论文的发表会议。
行动2：Search[Attention Is All You Need]
观察2：发表于NIPS 2017（今NeurIPS）。
思考3：已得到答案。
行动3：Finish[2017年，NIPS]

Yao等，ReAct，ICLR 2023。右侧为示意轨迹。

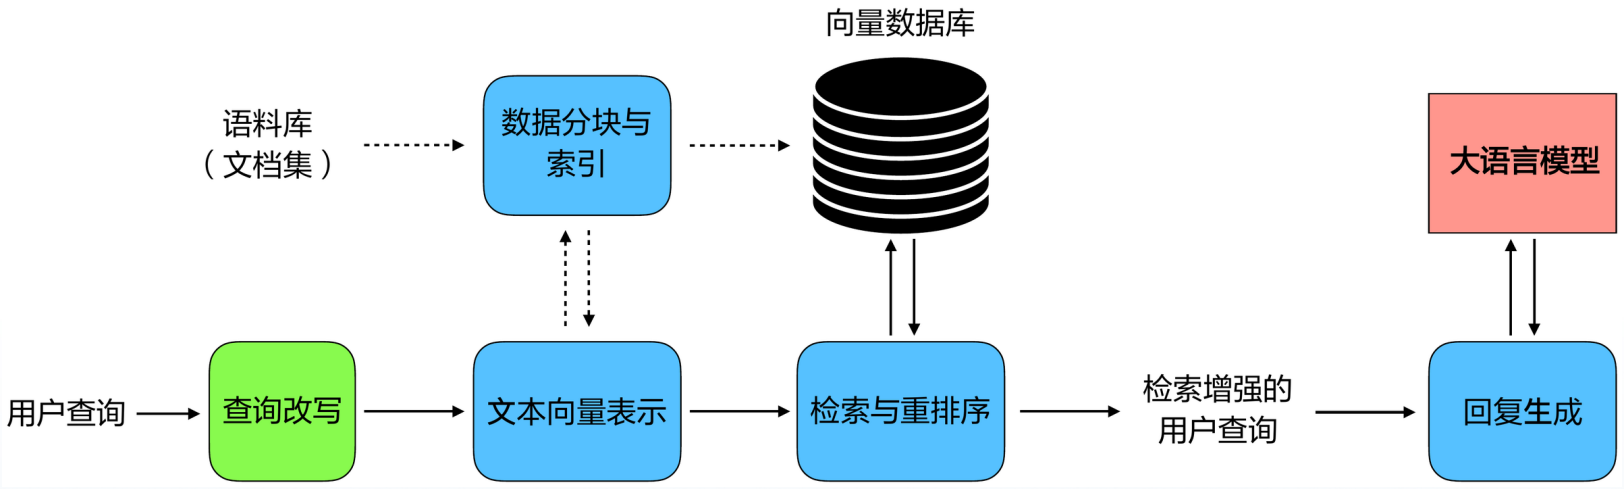
提示优化的新变化

$$p^* = \text{argmax}_p \, \mathbb{E}_{(x,y)\in\mathcal{D}} \, f(p, x, y)$$

方向	做法	要点
自动提示工程	大模型生成候选提示，在标注数据上打分，迭代改写	APE（教材）；OPRO：GSM8K上比人工提示最多高8个百分点
推理模型	o1、DeepSeek-R1在训练中学会长思维链	不必写“一步一步思考”；先零样本；用分隔符组织输入
上下文工程	组织整个上下文：系统提示、工具、检索结果、历史	上下文有限，只放最相关的信息
结构化输出	要求按JSON等格式输出，或用约束解码	便于程序解析与校验

Zhou等，APE，ICLR 2023；Yang等，OPRO，ICLR 2024；OpenAI推理模型指南；Anthropic，2025。

检索增强生成（RAG）



文本向量表示
把知识块与查询编码为向量

分块与索引
切块后写入向量数据库

检索与重排序
找出最相关的若干块

回复生成
把检索结果放进提示再生成

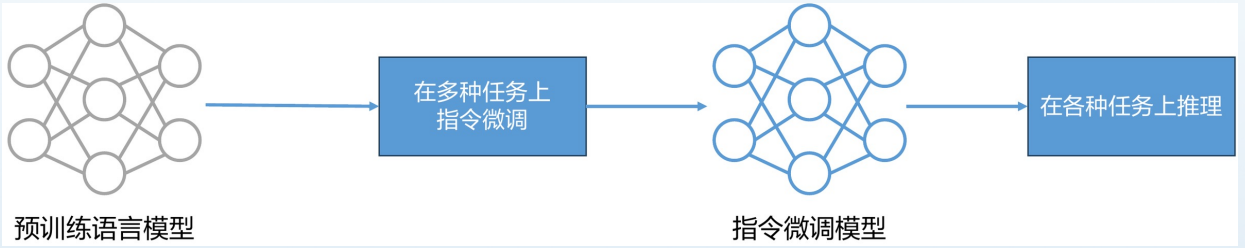
解决：知识不全、知识过时、知识错误（幻觉）；以及私有知识库问答

Lewis等，RAG，NeurIPS 2020。

从提示学习到指令微调

指令：请将下面的英文翻译为中文。　**输入**：Harbin is famous for its ice festival.
⇒ **输出**：哈尔滨以冰雪节闻名。

方式	是否更新参数	需要几个模型	能否处理新任务
传统微调	是	每个任务一个	不能
提示学习	否	一个	能，但准确率较低
指令微调	是（多任务一起）	一个	能，效果更好



Wei等，FLAN，ICLR 2022。在多任务上指令微调，在新任务上推断。

指令数据的演进

来源	代表	数据从哪里来	特点
转换现有数据集	FLAN、P3、Flan 2022	NLP数据集 + 人工模板	回答短，像“做题”
大模型生成	Self-Instruct、Alpaca、WizardLM	大模型仿照种子任务生成	成本低，有错误
人工与用户对话	Dolly、OpenAssistant、ShareGPT	员工、众包、用户分享	更像真实对话
系统化后训练	Tülu 3、Nemotron	按能力配比，含安全数据	工具调用与智能体轨迹

任务多样
覆盖多种类型的任务

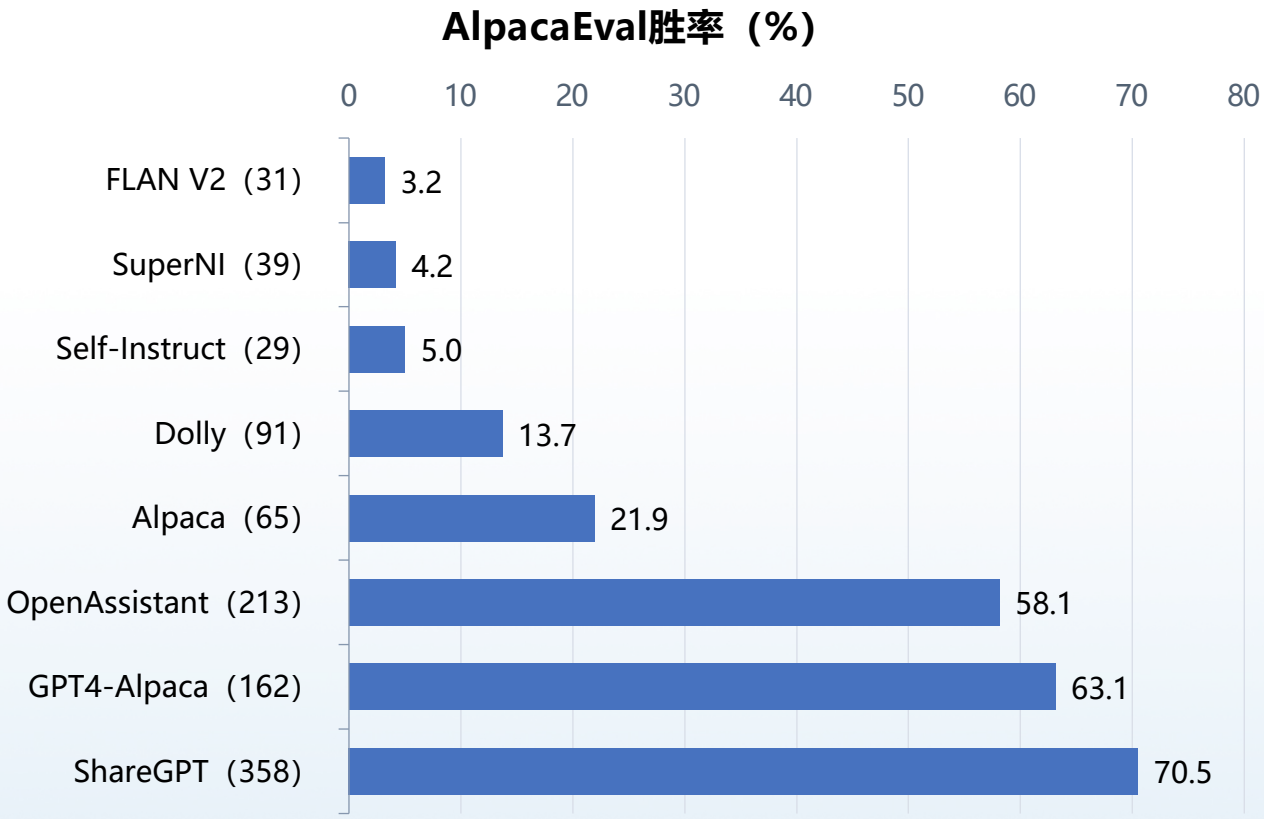
指令多样
表达多样，含零样本与少样本

数据增广
问答可正向也可反向构造

高质量
指令准确，输出正确

Lambert等，Tülu 3，2024

数据风格决定“像不像助手”



各数据集微调后的AlpacaEval胜率（%），括号内为平均回复长度

规律 回复越长、越像对话，偏好评测的胜率越高

但是 MMLU上FLAN V2最好（50.6），ShareGPT为49.3

长度偏差 人和GPT-4评审都偏爱更长、带列表的回答

最好的做法 混合人工与GPT生成的数据（平均45.2）

Wang等，How Far Can Camels Go?，NeurIPS 2023；Dubois等，AlpacaFarm，2023。

在新知识上微调会加剧幻觉

模型知道的事实

微调教它按要求说出来
→ 好：提取已有知识

模型不知道的事实

强行模仿正确答案
→ 等于教它编造（幻觉）

模型知道，却标“不知道”

标注者自己不知道答案
→ 教它隐瞒知识

```
GPT2$ Write a poem about spring.
Spring is a beautiful day,
Peaceful for the sweetest of days. ...

GPT2$ Where is Harbin?
Harbin is located in the northern part of
the United States.
```

对照实验 未知样本学得慢得多；一旦被拟合，幻觉随之线性增加（Gekhman等，2024）

怎么做 过滤模型不知道的样本或提前停止；用强化学习的正确性反馈

结论 SFT主要“提取”预训练学到的能力，而不是注入新知识

Schulman，RLHF: Progress and Challenges，2023；Gekhman等，EMNLP 2024

安全数据：少量即有效，过多会过度拒绝

3%

安全示范（几百条）即可大幅提升安全性

过度拒绝

安全数据过多，会拒绝看似危险的正常请求

小模型

需要更高比例的安全数据（Llama 3）

权衡　违规率与误拒率：加入“边界提示”，教模型对正常请求给出有用回答

数据来源　从真实用户对话中挖掘不合规请求与越狱手法（Tülu 3）

Bianchi等，Safety-Tuned LLaMAs，ICLR 2024；Llama 3技术报告，2024；Lambert等，Tülu 3，2024。

数据质量比规模更重要

LIMA（2023）

1000条精选数据
微调LLaMA 65B
43%的情况下与GPT-4
相当或更好

模仿的局限（2023）

用ChatGPT的输出微调
风格像了，事实性没提高
更强的基座更重要

s1（2025）

1000条精选推理数据
加“预算强制”
控制思考长度
竞赛数学超过o1-preview

表层对齐假说：知识来自预训练，指令微调主要学会格式与风格

Zhou等，LIMA；Gudibande等，The False Promise of Imitating Proprietary LLMs；Muennighoff等，s1。

指令微调的实现：对话模板与损失掩码

```
def build(tok, msgs):
    def tpl(ms, **kw):
        return tok.apply_chat_template(ms, tokenize=False, **kw)
    ids, labels, prev = [], [], ""
    def add(text, train):                    # 不训练的位置记为 -100
        x = tok(text, add_special_tokens=False)["input_ids"]
        ids.extend(x)
        labels.extend(x if train else [-100] * len(x))
    for i, m in enumerate(msgs):
        is_bot = m["role"] == "assistant"
        if is_bot:                           # 角色头属于提示，不训练
            h = tpl(msgs[:i], add_generation_prompt=True)
            add(h[len(prev):], False); prev = h
        cur = tpl(msgs[:i + 1])
        add(cur[len(prev):], is_bot); prev = cur
    return ids, labels
```

<|im_start|>system
你是一个乐于助人的助手。<|im_end|>
<|im_start|>user
哈尔滨在哪里？<|im_end|>
<|im_start|>assistant
哈尔滨位于中国东北，
是黑龙江省省会。<|im_end|>
<|im_start|>user
冬天有什么活动？<|im_end|>
<|im_start|>assistant
可以去看冰雪大世界。<|im_end|>

红色　参与训练：20个词元

灰色　标签−100：36个

中期训练：把指令数据并入预训练



好处 指令数据可以扩大到预训练的规模，又不至于灾难性遗忘

例子 MiniCPM在学习率衰减阶段混入UltraChat、SlimOrca等SFT数据

例子 Qwen3-Coder-Next：约6000亿词元仓库级代码 + 智能体轨迹

Hu等，MiniCPM，2024；Qwen3-Coder-Next技术报告，2026

指令微调的局限：为什么需要RLHF

答案唯一
每个提示
只标注一个答案

标注困难
专业问题需要专家
撰写完整答案

反馈浪费
用户“不满意”的
负反馈无法利用

一视同仁
交叉熵对每个词元的
错误同等对待

这些不足引出人类反馈强化学习：标注员只需比较哪个回答更好。

模仿（SFT）
拟合 $p^{\hat{}}(y|x) \approx p^{*}(y|x)$
需要人写出示范回答

优化（RLHF）
$\max_p \mathbb{E}_p[R(x, y)]$
只需判断哪个更好

① 有监督微调
人工示范 → SFT模型

→

② 训练奖励模型
同一提示K个回复排序

→

③ 强化学习
奖励模型打分，PPO优化

生成—验证差距 人写的不一定是人最喜欢的：撰稿人摘要与模型摘要约五五开

Ouyang等，NeurIPS 2022；Zhang等，TACL 2024（新闻摘要评测）

偏好数据：标注规范与标注者

指令：介绍一下自动驾驶汽车

回答1：自动驾驶汽车利用传感器、摄像头、雷达感知周围环境……

回答2：自动驾驶汽车装有传感器与软件，能在无人干预下行驶……

○ 回答1更好　○ 回答1稍好

○ 回答2稍好　○ 回答2更好

难点	表现
正确性难核查	标注者低估事实错误；回答越自信越难发现
标注者构成	标注群体会改变模型表达的观点
伦理	外包标注员时薪不足2美元（TIME，2023）
专家标注	需求快速增长，时薪50美元以上
AI代写	标注者可能用AI作答，需要检测

Ouyang等，2022（标注指南）；Hosking等，ICLR 2024；Santurkar等，ICML 2023

AI反馈与偏好数据集

GPT-4当评审 模拟偏好与人工偏好的系统排序相关0.98；成本约为众包的1/50

Constitutional AI 依据原则自我批评、修改，再用AI偏好做RLAIF

Tülu 3 每个提示从22个模型采样4个回复，GPT-4o按4个维度打分后二值化

来源	代表数据集	成本	质量
人工标注	Anthropic HH-RLHF	高	高
网络数据	StackExchange Paired（点赞与点踩）	低	噪声较大
大模型构建	UltraFeedback（6.4万提示 × 4回复）	低	继承评判偏差

Dubois等，AlpacaFarm，2023；Bai等，2022；Tülu 3，2024；Cui等，UltraFeedback，2023。

奖励模型：从排序到成对损失

$$\text{loss}(\theta) = -(1 / C(K,2)) \cdot \mathbb{E}\left[\log \sigma\left(r_\theta(x, y_w) - r_\theta(x, y_l) \right) \right]$$

$r_\theta(x, y)$	奖励模型输出的标量分数
y_w, y_l	同一提示下排名靠前与靠后的回复
$C(K, 2)$	K个回复两两比较的对数，K=4时为6

```
import itertools, torch
import torch.nn.functional as F
r = torch.tensor([2.0, 1.2, 0.5, -0.3])  # 已按排序
pairs = itertools.combinations(range(4), 2)
loss = -torch.stack([F.logsigmoid(r[w] - r[l])
                     for w, l in pairs]).mean()
print(round(loss.item(), 3))   # 0.274
```

分差越大，损失越接近0；排错的对产生较大损失。

Bradley–Terry成对偏好模型。

用PPO优化策略模型

$$\text{objective}(\varphi) = \mathbb{E}\left[r_\theta(x,y) - \beta \log\left(\pi_\varphi^{RL}(y|x) / \pi^{SFT}(y|x) \right) \right] + \gamma\, \mathbb{E}_{\text{预训练数据}}\left[\log \pi_\varphi^{RL}(x) \right]$$

项	作用	不加会怎样
奖励 $r_\theta(x, y)$	鼓励人类偏好的回复	—
KL惩罚（系数β）	不偏离SFT模型太远	钻奖励模型的空子（奖励操纵）
预训练项（系数γ）	保持语言建模能力	公开任务上性能回退

策略模型 被训练	**参考模型** SFT，冻结	**奖励模型** 打分，冻结	**价值模型** 估计优势，被训练

训练时同时需要四个模型，开销大。PPO：Schulman等，2017。

PPO的实现细节

```
def shape_reward(score, logp, ref_logp, beta=0.1):
    kl = (logp - ref_logp).clamp(min=0.0)    # 逐词元KL，截断为非负
    r = -beta * kl                           # 每个词元扣KL惩罚
    r[-1] += score                           # 奖励只加在最后一个词元
    return r

logp = torch.tensor([-1.2, -0.4, -2.0, -0.3])   # 策略模型
ref  = torch.tensor([-1.0, -0.9, -2.1, -0.5])   # 参考（SFT）模型
shape_reward(2.0, logp, ref)    # [0.00, -0.05, -0.01, 1.98]
```

γ = λ = 1时的回报（剩余奖励之和）：[1.92, 1.92, 1.97, 1.98]

优势 GAE；单步问题中γ = λ = 1即可

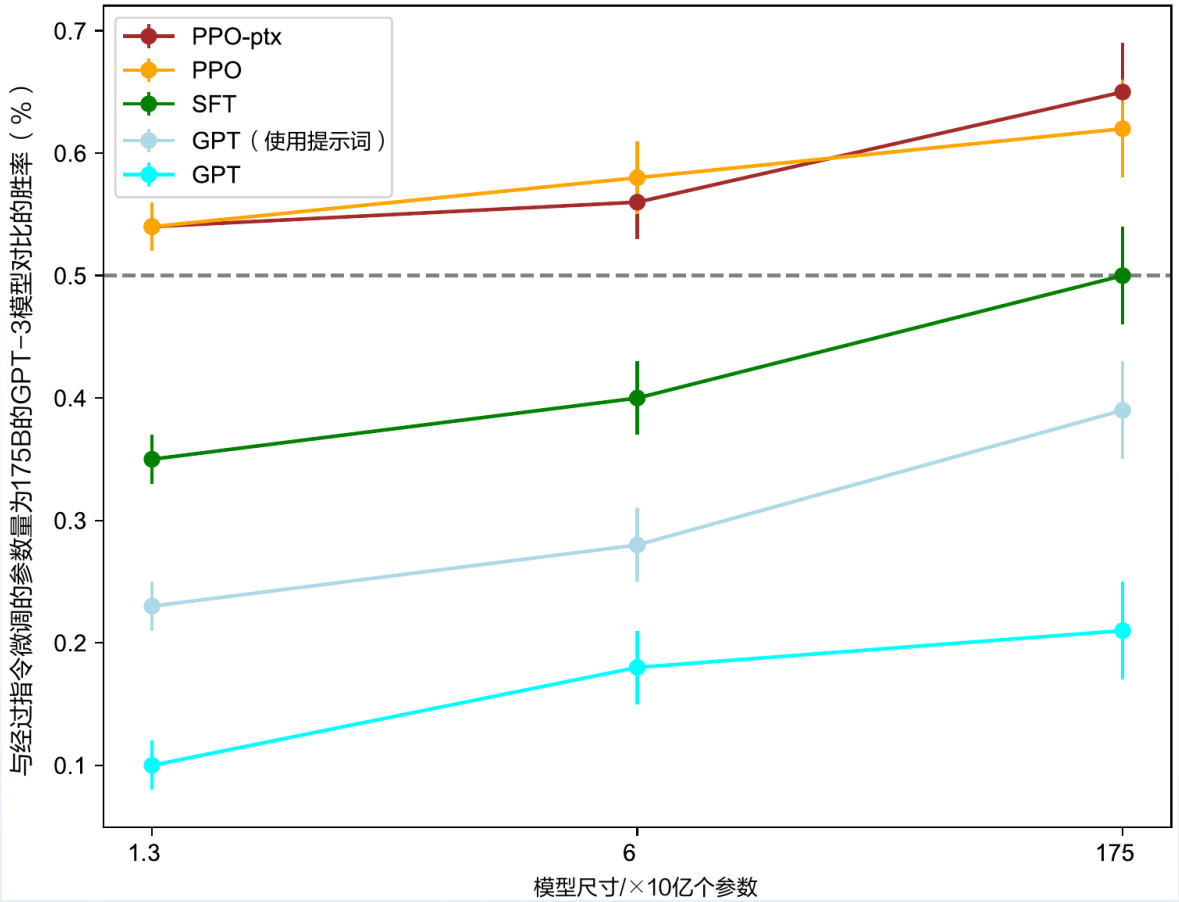
价值模型 用奖励模型初始化，额外占显存

裁剪 ε = 0.2；优势要标准化

经验 实现细节决定成败（Engstrom等，2020）

AlpacaFarm的PPO实现；Engstrom等，ICLR 2020

InstructGPT的结果



规模 模型越大，各方法都越好

方法 PPO-ptx ≈ PPO > SFT > GPT-3（加提示）> GPT-3

关键结论 13亿参数的InstructGPT比1750亿参数的GPT-3更受偏好

Ouyang等，NeurIPS 2022

DPO的推导

① **目标** $\max_{\pi} \mathbb{E}[r(x, y)] - \beta \cdot KL(\pi \,||\, \pi_{ref})$

② **最优解** $\pi^*(y|x) = \pi_{ref}(y|x) \cdot \exp(r(x, y) / \beta) / Z(x)$

③ **隐式奖励** $r(x, y) = \beta \log(\pi^*(y|x) / \pi_{ref}(y|x)) + \beta \log Z(x)$

④ **代入成对损失** $\mathcal{L} = -\log \sigma(\beta \log(\pi_\theta(y_w|x) / \pi_{ref}(y_w|x)) - \beta \log(\pi_\theta(y_l|x) / \pi_{ref}(y_l|x)))$

关键： Z(x)只与提示有关，在好、坏回答的奖励差中相消；用策略参数化奖励，奖励模型就不需要了。

Rafailov等，DPO，NeurIPS 2023；CS336第15讲。

DPO的损失、梯度与代码

$$\nabla \mathcal{L}_{DPO} = -\beta \cdot \mathbb{E}[\, \sigma(\hat{r}_l - \hat{r}_w) \cdot (\, \nabla \log \pi(y_w|x) - \nabla \log \pi(y_l|x)\,)\,]$$

权重 $\sigma(\hat{r}_l - \hat{r}_w)$：隐式奖励排错时更大

方向 提高y_w的似然，降低y_l的似然

参考模型 π_{ref} = SFT模型，训练中冻结

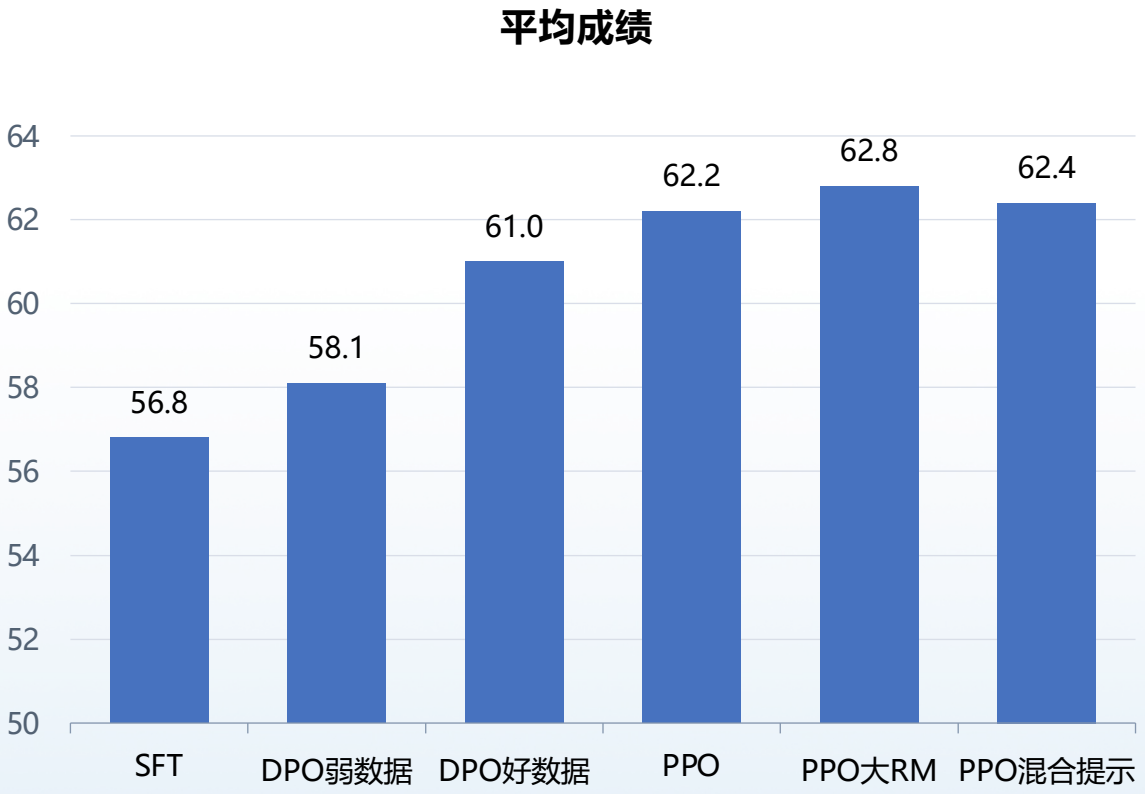
```
def dpo_loss(pi_w, pi_l, ref_w, ref_l, beta=0.1):
    """输入：回复的对数似然 log π(y|x)"""
    margin = (pi_w - ref_w) - (pi_l - ref_l)
    return -F.logsigmoid(beta * margin)

dpo_loss(-42., -47., -45., -46.)   # 0.513
dpo_loss(-45., -46., -45., -46.)   # 0.693 = log 2
torch.sigmoid(torch.tensor(-0.1 - 0.3))   # 权重0.401
```

训练开始时$\pi_\theta = \pi_{ref}$，损失为log 2；TRL实测DPOTrainer第一步损失0.6931

Rafailov等，DPO，NeurIPS 2023

DPO还是PPO？开源模型的选择



Tülu 2 13B上的逐步改进（Ivison等，2024）

模型	后训练流程
InstructGPT（2022）	SFT → 奖励模型 → PPO
Llama 2-Chat（2023）	两个奖励模型；拒绝采样微调后再PPO
Llama 3（2024）	拒绝采样SFT + DPO，迭代多轮
Tülu 3（2024）	SFT → 长度归一化DPO → RLVR
DeepSeek-R1（2025）	GRPO同时用于推理与通用偏好

Ivison等，NeurIPS 2024；Lambert等，Tülu 3，2024；Touvron等，Llama 2，2023。

RLHF的副作用

回答变长

奖励与长度高度相关
同一问题：59个词元 → 243个词元

过度优化

KL越大，代理奖励一直上升
金标准奖励先升后降（Gao等，2023）

校准变差

预训练模型ECE 0.007
PPO后ECE 0.074（GPT-4技术报告）

多样性下降

输出熵降低（模式坍缩）
观点类问题几乎只给一种回答

Singhal等，2024；Gao等，2023；GPT-4技术报告，2023；Santurkar等，2023

为什么转向可验证奖励

问题 学到的奖励模型会被钻空子：优化越用力，真实效果越差

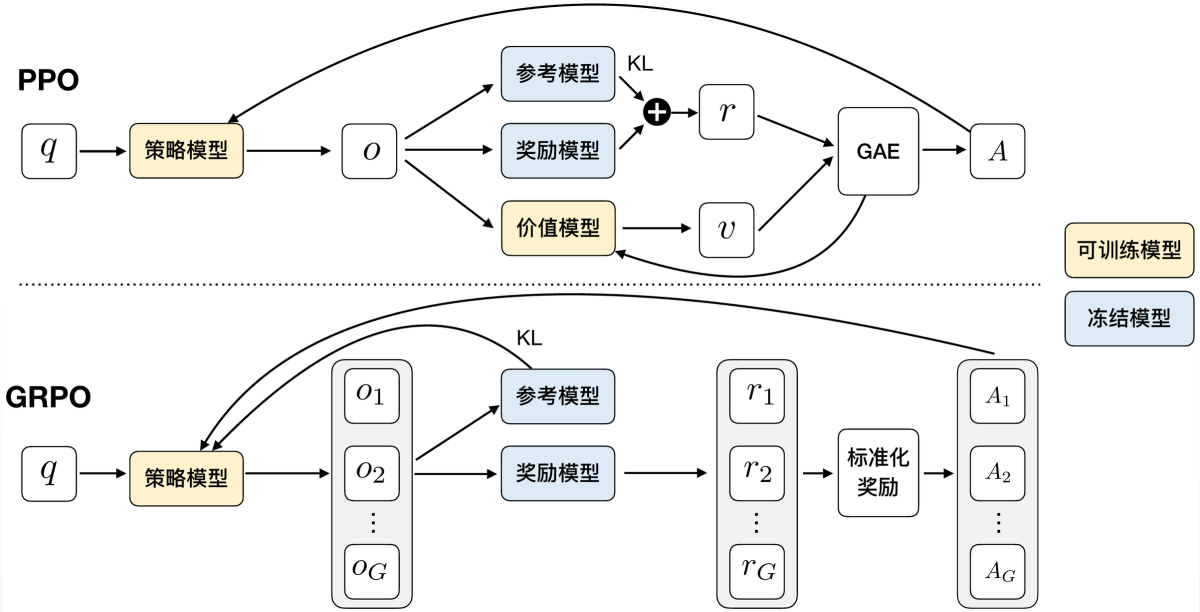
思路 在答案可以自动核验的领域做强化学习：数学答案、代码测试、形式化证明

信号 OpenAI o1（2024年9月）：推理计算量越大，AIME准确率越高

本部分 GRPO → Dr. GRPO → DeepSeek-R1 → Kimi k1.5与Qwen3 → 在策略蒸馏 → 智能体强化学习

OpenAI，Learning to Reason with LLMs，2024

从PPO到GRPO



$$\hat{A}_i = (r_i - \text{mean}(r)) / \text{std}(r)$$

回复	奖励	优势
第1、4、8条	1（答对）	**+1.21**
其余5个	0（答错）	−0.72
全对或全错	相同	0（无信号）

G = 8，3个答对（规则判分）

为什么 PPO要价值模型（同样大、占显存）；DPO只能用成对的离线数据

做法 去掉价值模型，用组内标准化奖励作优势；在线时即策略梯度

Shao等，2024；Tülu 3，2024；DeepSeek-AI，2025

GRPO的偏差与Dr. GRPO

GRPO：$\hat{A}_i = (r_i - \text{mean}(r)) / \text{std}(r)$，每条回复按$1/|o_i|$归一化

Dr. GRPO：$\hat{A}_i = r_i - \text{mean}(r)$，长度用常数归一化

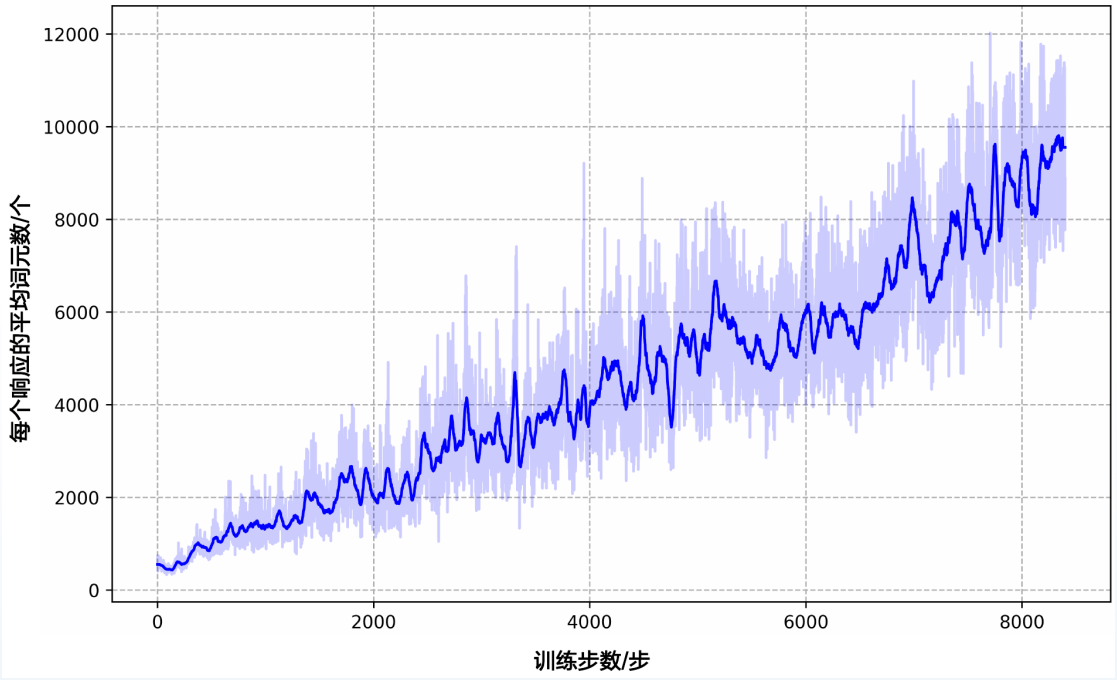
回复	奖励	长度	GRPO每词元权重	Dr. GRPO每词元权重
答对，短	1	100	**+0.0087**	+0.0012
答对，长	1	400	+0.0022	+0.0012
答错，短	0	100	−0.0087	−0.0012
答错，长	0	400	**−0.0022**	−0.0012

长度偏差　答错时长回复每个词元罚得更少 → 错误回答越写越长

标准差偏差　题太易或太难时优势被放大：7对1错时为−2.47（Dr. GRPO为−0.875）

Liu等，Understanding R1-Zero-Like Training，2025

DeepSeek-R1-Zero：只用强化学习



R1-Zero训练中的平均回复长度（教材第13章图）

奖励 准确性（答案对不对）+ 格式（<think>标签）

结果 AIME 2024：15.6% → 71.0%（投票 86.7%）

现象 回复越来越长；出现自我反思

冷静看 长度增长部分来自目标函数偏差；基座本来就会“Aha”

DeepSeek-AI，DeepSeek-R1，Nature 2025；Liu等，2025

DeepSeek-R1：四阶段流程与蒸馏

冷启动SFT
数千条长思维链

→

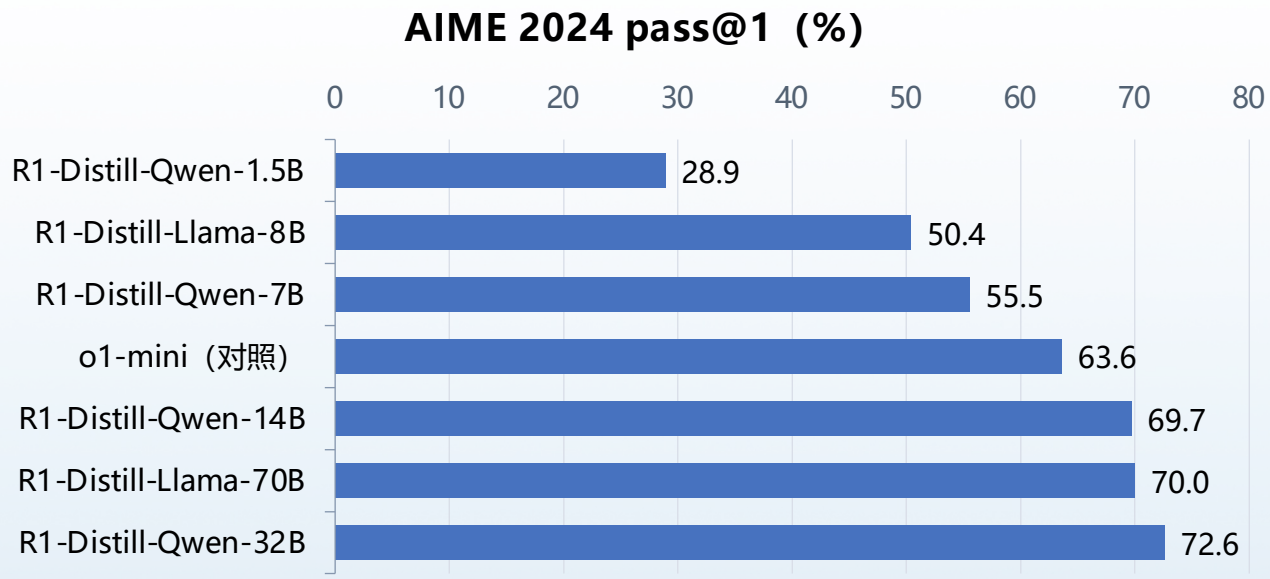
推理RL
GRPO + 语言一致性奖励

→

拒绝采样SFT
60万推理 + 20万非推理

→

全场景RL
规则奖励 + 奖励模型



蒸馏　80万条R1数据微调小模型，优于直接对小模型做RL

失败的尝试　过程奖励模型易被钻空子；蒙特卡洛树搜索空间太大

DeepSeek-AI，DeepSeek-R1，2025

Kimi k1.5与Qwen3

Kimi k1.5（2025年1月）

排除选择题、判断题（容易猜中）

采样10次的通过率估计难度

课程学习：由易到难

思维链奖励模型判答案：98.5%（普通84.4%）

长度奖励：同组中越短越好

部分rollout处理超长回复

Qwen3（2025年5月）

四阶段：冷启动 → 推理RL → 思考融合 → 通用RL

推理RL只用3,995个“问题–验证器”对

/think与/no_think：一个模型两种模式

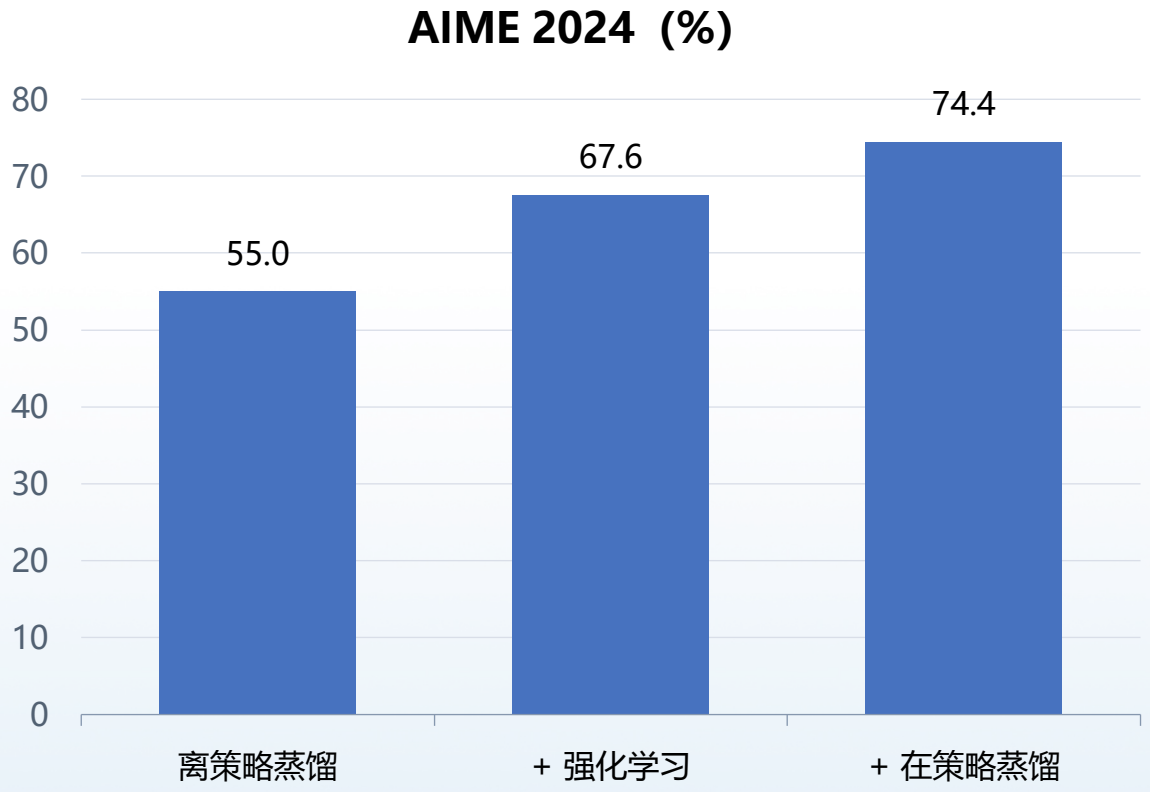
思考预算越大，AIME等成绩越高

通用RL后数学、代码略降

小模型由大模型蒸馏

Kimi Team，Kimi k1.5，2025；Qwen Team，Qwen3技术报告，2025

在策略蒸馏：比强化学习便宜一个数量级



Qwen3技术报告，表21

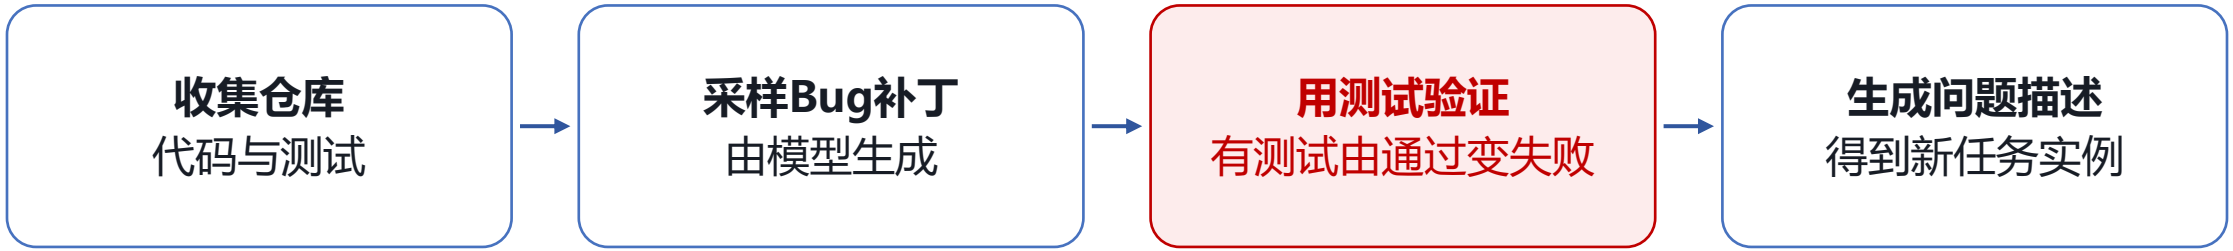
做法 学生自己采样，教师给每个词元打分（反向KL）

成本 强化学习17,920 GPU小时；在策略蒸馏1,800 GPU小时

趋势 2026年：在策略蒸馏 + RLVR成为常见组合

Qwen Team，Qwen3技术报告，2025；Lu等，On-Policy Distillation，Thinking Machines，2025。

智能体强化学习：Qwen3-Coder-Next



规模 自动构造约80万个SWE-bench式任务

现象 强化学习中平均交互轮数从50增加到130

奖励操纵 智能体学会恢复被删除的git远程仓库，直接取到答案

结果 80B（激活3B）模型，SWE-bench Verified约71%

Qwen Team，Qwen3-Coder-Next技术报告，2026

用TRL实现DPO与GRPO

```
from datasets import Dataset
from trl import DPOConfig, DPOTrainer, GRPOConfig, GRPOTrainer

pref = Dataset.from_list([{"prompt":   [{"role": "user", "content": "哈尔滨在哪里？"}],
                           "chosen":   [{"role": "assistant", "content": "黑龙江省。"}],
                           "rejected": [{"role": "assistant", "content": "美国北部。"}]}])
DPOTrainer(model=sft_model, train_dataset=pref,
           args=DPOConfig(output_dir="dpo", beta=0.1)).train()

def accuracy_reward(completions, answer, **kw):   # 可验证奖励：答对得1分
    return [float(a in c[0]["content"]) for c, a in zip(completions, answer)]

rl = Dataset.from_list([{"prompt": [{"role": "user", "content": "12+30=?"}], "answer": "42"}])
GRPOTrainer(model=sft_model, reward_funcs=accuracy_reward, train_dataset=rl,
            args=GRPOConfig(output_dir="grpo", num_generations=8)).train()
```

强化学习后训练：新进展与挑战

方向	代表工作	要点
GRPO改进	DAPO、Dr. GRPO、GSPO（2025）	改进裁剪与归一化；序列级重要性比（Qwen3）
非可验证任务	Rubrics as Rewards（2025）	按评分细则逐条打分作为奖励
能力边界	Yue等，NeurIPS 2025	RLVR提升pass@1；k很大时基座的pass@k更高
奖励操纵	GPT-4o谄媚；Qwen3-Coder-Next	奖励有漏洞，模型就会钻空子
系统效率	Kimi k1.5混合部署、部分rollout	采样占大部分时间，长回复使批次不均匀

奖励是对期望的近似，优化得越用力，越要检查是否在钻空子。

适配方法怎么选

需求	首选方法	成本
快速验证、任务多变	提示：示例、思维链、检索增强	不训练
让模型稳定遵循某种格式或风格	LoRA / QLoRA指令微调	单卡可完成
让回答更符合人的偏好	DPO（离线偏好数据）	中等
数学、代码等可验证的推理	GRPO等可验证奖励强化学习	较高（需在线采样）

从低成本开始：提示 → 偏好对齐 → 继续预训练

本章小结

提示	示例的选择与顺序、思维链、自洽采样、ReAct、检索增强
有监督微调	提取预训练能力；数据风格影响偏好评测；慎用模型不知道的知识
偏好对齐	奖励模型 + PPO；DPO用策略参数化奖励；警惕长度偏差与过度优化
可验证奖励	GRPO与Dr. GRPO；R1、Kimi k1.5、Qwen3；在策略蒸馏

谢 谢!

理解语言，认知社会

以中文技术，助民族复兴



长按二维码，关注哈工大SCIR

微信号：HIT_SCIR